

Baseline Evaluation of Large Language Models for Empathetic Response Generation

A Comparative Study of Llama-3.1-8B and DeepSeek-7B Using Multidimensional Empathy
Metrics

Author Name

Affiliation

Date: 2026-01-06

Abstract

본 연구는 대규모 언어 모델(LLM)의 공감적 응답 생성 능력을 평가하기 위한 다차원 공감 메트릭 시스템을 제안하고, 이를 활용하여 Llama-3.1-8B-Instruct와 DeepSeek-7B-Chat 모델의 성능을 비교 분석하였다. 평가에는 구체성(Specificity), 반영 수준(Reflection Level), 단어 선택(Word Choice), 다양성(Diversity)의 4가지 차원이 사용되었다. 실험 결과, Llama-3.1-8B 모델이 Overall Score 0.757로 DeepSeek-7B 모델(Overall Score 0.674)보다 우수한 공감 능력을 보였다. 특히 반영 수준(Reflection Level)에서 Llama 모델이 현저히 높은 점수를 기록하였으며, 이는 감정 인식 및 반영 표현의 사용 빈도가 더 높음을 나타낸다. 본 연구의 평가 프레임워크는 향후 공감 정렬(Empathy Alignment) 연구의 기초 자료로 활용될 수 있다.

Keywords: empathy alignment, large language models, multidimensional evaluation, emotional intelligence, natural language generation

Introduction

인공지능 챗봇과 대화형 에이전트의 발전으로 인해 LLM의 공감 능력에 대한 관심이 증가하고 있다. 사용자가 감정적인 상황을 공유할 때, AI 시스템이 적절한 공감적 응답을 생성하는 것은 사용자 경험과 신뢰 구축에 중요한 역할을 한다.

기존 연구들은 주로 단일 차원의 공감 평가에 의존하였으나, 공감은 본질적으로 다차원적인 개념이다. Sharma et al. (2020)의 EPITOME 프레임워크와 EACL 2024 논문에서 제시된 4가지 핵심 차원을 바탕으로, 본 연구는 구체성, 반영 수준, 단어 선택, 다양성의 4가지 메트릭을 구현하여 LLM의 공감 능력을 종합적으로 평가하였다.

본 연구의 목적은 (1) 다차원 공감 평가 프레임워크를 구축하고, (2) 대표적인 오픈소스 LLM들의 baseline 공감 능력을 측정하며, (3) 향후 fine-tuning을 통한 공감 정렬 연구의 기초 자료를 마련하는 것이다.

Method

Models

본 연구에서는 두 가지 오픈소스 LLM을 평가하였다:

Table 1

평가 대상 모델 정보

Model	Parameters	Type	Developer
Llama-3.1-8B-Instruct	8B	Instruction-tuned	Meta AI
DeepSeek-7B-Chat	7B	Chat-tuned	DeepSeek AI

Evaluation Metrics

공감적 응답의 품질을 평가하기 위해 4가지 메트릭을 사용하였다. 각 메트릭은 선행 연구에서 검증된 방법론을 기반으로 구현되었다.

Table 2
4가지 공감 평가 메트릭 및 데이터 소스

Metric	Description	Data Source	Range
Specificity	응답의 구체성 수준	Brysbaert et al. (2014) 39,954 words	1.0 - 5.0
Reflection Level	감정 반영의 깊이	PAIR Model patterns (Min et al., 2022)	0 - 6
Word Choice	VAD 감정 정렬도	NRC VAD Lexicon 54,801 words	0.0 - 1.0
Diversity	표현의 다양성	Distinct-n (Li et al., 2016)	0.0 - 1.0

Note. Overall Score는 각 메트릭을 정규화(0-1)한 후 동일 가중치(25%)로 결합하여 산출.

Test Prompts

평가에는 다양한 감정 상황을 포함한 10개의 테스트 프롬프트가 사용되었다. 프롬프트는 슬픔, 기쁨, 불안, 혼란, 외로움 등 다양한 감정 상태를 포함하도록 설계되었다.

Table 3
테스트 프롬프트 목록

#	Context (요약)	Emotion
1	5년 다니던 직장에서 갑자기 해고됨	sadness/shock
2	친한 친구가 몇 주째 연락이 없음	confusion/hurt
3	의사 시험 3번 실패 후 합격	joy/relief
4	30년 결혼한 부모님 이혼 소식	confusion/sadness
5	불안감과 불면증으로 고통	anxiety
6	12년 함께한 반려견 사망	grief
7	꿈의 대학교 합격	excitement/pride
8	아무도 나를 이해하지 못하는 느낌	loneliness
9	파트너가 3년 연속 기념일을 잊음	disappointment/hurt

Results

Overall Performance Comparison

Table 4는 두 모델의 전체 성능을 비교한 결과이다. Llama-3.1-8B 모델이 Overall Score 0.757로 DeepSeek-7B 모델(0.674)보다 0.082점 높은 성능을 보였다.

Table 4
모델별 공감 메트릭 점수 비교

Metric	Llama-3.1-8B	DeepSeek-7B	Difference	Max
Specificity	2.436	2.427	+0.010	5.0
Reflection Level	4.80	2.70	+2.10	6.0
Word Choice	0.921	0.929	-0.008	1.0
Diversity	0.819	0.834	-0.015	1.0
Overall Score	0.757	0.674	+0.082	1.0

Note. Difference = Llama - DeepSeek. 양수는 Llama가 우수함을 의미.

Figure 1




Figure 1. 4가지 공감 메트릭에 대한 모델별 정규화 점수 비교 (레이더 차트). 모든 메트릭은 0-1 범위로 정규화됨. 외곽에 가까울수록 높은 성능을 나타냄.

Detailed Analysis by Metric

Specificity (구체성)

두 모델 모두 구체성 점수에서 유사한 성능을 보였다 (Llama: 2.436, DeepSeek: 2.427). 이는 두 모델 모두 비슷한 수준의 추상적 언어를 사용함을 나타낸다. Lexicon coverage는 약 89%로, 대부분의 단어가 Brysbaert et al. (2014)의 구체성 사전에서 매칭되었다.

Reflection Level (반영 수준)

반영 수준에서 두 모델 간 가장 큰 차이가 관찰되었다. Llama 모델(4.80/6.0)은 DeepSeek 모델(2.70/6.0)보다 2.10점 높은 점수를 기록하였다. 이는 Llama 모델이 'It sounds like you're feeling...', 'That must be...'와 같은 감정 반영 표현을 더 빈번하게 사용함을 의미한다.

Word Choice (단어 선택)

VAD(Valence-Arousal-Dominance) 기반 단어 선택 분석에서 두 모델 모두 높은 공감 정렬도를 보였다 (Llama: 0.921, DeepSeek: 0.929). 이는 두 모델 모두 차분하고 따뜻한 톤의 단어를 선택하는 데 성공적임을 나타낸다.

Diversity (다양성)

다양성 메트릭에서 두 모델은 유사한 성능을 보였다 (Llama: 0.819, DeepSeek: 0.834). Corpus-level Distinct-2 점수는 Llama 0.644, DeepSeek 0.671로, 두 모델 모두 다양한 표현을 사용하는 것으로 나타났다.

Discussion

본 연구의 결과는 LLM의 공감 능력이 모델에 따라 상당한 차이를 보일 수 있음을 시사한다. 특히 반영 수준(Reflection Level)에서 관찰된 큰 차이는 instruction-tuning 과정에서 사용된 데이터와 학습 방법의 영향을 받았을 가능성이 있다.

Llama-3.1-8B 모델이 DeepSeek-7B 모델보다 우수한 공감 능력을 보인 것은 Meta AI의 RLHF(Reinforcement Learning from Human Feedback) 과정에서 공감적 응답에 대한 선호가 반영되었을 수 있음을 암시한다. 그러나 두 모델 모두 구체성 점수가 상대적으로 낮은 것은 사용자의 구체적인 상황을 언급하기보다 일반적인 공감 표현을 사용하는 경향이 있음을 보여준다.

본 연구의 한계점으로는 (1) 테스트 프롬프트의 수가 제한적이며, (2) 영어 응답만을 평가하였고, (3) 인간 평가자의 주관적 공감 평가와의 상관관계를 검증하지 않았다는 점이 있다. 향후 연구에서는 EPITOME 데이터를 활용한 Supervised Fine-Tuning(SFT)과 Direct Preference Optimization(DPO)을 통해 모델의 공감 능력을 향상시키고, 본 연구에서 구축한 메트릭으로 그 효과를 검증할 예정이다.

Conclusion

본 연구는 4가지 다차원 공감 메트릭을 사용하여 Llama-3.1-8B와 DeepSeek-7B 모델의 공감적 응답 생성 능력을 평가하였다. 실험 결과, Llama-3.1-8B 모델이 Overall Score 0.757로 DeepSeek-7B 모델(0.674)보다 우수한 성능을 보였다. 특히 반영 수준에서 Llama 모델이 현저히 높은 점수를 기록하였다.

본 연구에서 구축한 다차원 공감 평가 프레임워크는 LLM의 공감 능력을 객관적으로 측정하고 비교하는 데 유용한 도구로 활용될 수 있다. 향후 EPITOME 데이터를 활용한 fine-tuning과 DPO를 통해 LLM의 공감 능력을 향상시키는 Empathy Alignment 연구로 확장할 예정이다.

References

- Brysbaert, M., Warriner, A. B., & Kuperman, V. (2014). Concreteness ratings for 40 thousand generally known English word lemmas. *Behavior Research Methods*, 46(3), 904-911.
- Houck, J. M., Moyers, T. B., Miller, W. R., Glynn, L. H., & Hallgren, K. A. (2012). Motivational Interviewing Skill Code (MISC) 2.5.
- Li, J., Galley, M., Brockett, C., Gao, J., & Dolan, B. (2016). A diversity-promoting objective function for neural conversation models. *Proceedings of NAACL-HLT*, 110-119.
- Min, S., Lim, J., & Choi, Y. (2022). PAIR: Prompt-aware margin ranking for counselor reflection generation. *Proceedings of ACL*.
- Mohammad, S. M. (2018). Obtaining reliable human ratings of valence, arousal, and dominance for 20,000 English words. *Proceedings of ACL*, 174-184.
- Sharma, A., Lin, I. W., Miner, A. S., Atkins, D. C., & Althoff, T. (2020). A computational approach to understanding empathy expressed in text-based mental health support. *Proceedings of EMNLP*.

Appendix: Sample Responses

다음은 첫 번째 테스트 프롬프트(직장 해고 상황)에 대한 각 모델의 응답 예시이다.

Context:

"I just lost my job today. I've been working there for 5 years and they just let me go without any warning."

Llama-3.1-8B Response:

"I'm so sorry to hear that. Losing a job can be really tough, especially when it feels unexpected. Five years is a long time to be with a company, and I can imagine how attached you must feel to the people and the work. It's like a part of your identity has been taken away from you. Can you tell me a bit more about how you're feeling right now? Is it anger, sadness, or something else?..."

DeepSeek-7B Response:

"I'm sorry to hear that you lost your job today. Losing a job can be a difficult and stressful experience, especially when it comes unexpectedly. It's understandable that you might be feeling a range of emotions right now, such as sadness, frustration, or even anger. It's important to remember that you are not alone in this situation, and that many people have gone through something similar. While it may be difficult to see the bright side right now, try to focus on the fact that you have experi..."