

Empathy Alignment 프로젝트: 4가지 공감 평가 메트릭 상세 문서

LLM의 공감 능력 평가를 위한 다차원적 메트릭 구현 가이드

Technical Documentation

Version 1.0

개요

본 문서는 LLM(Large Language Model)의 공감 능력을 평가하기 위한 4가지 핵심 차원의 메트릭 구현에 대해 상세히 설명한다. 이 메트릭들은 Lee et al. (2024)의 EACL 논문 "A Comparative Multidimensional Analysis of Empathetic Systems"에서 제시된 다차원적 공감 평가 프레임워크를 기반으로 한다.

이론적 배경

공감(Empathy)은 단일 점수로 측정하기 어려운 복잡한 다차원적 구조이다 (Davis, 1983; Cuff et al., 2016). Lee et al. (2024)은 기존 공감 대화 시스템 평가의 한계를 지적하며, 단일 공감 점수 대신 여러 차원에서의 평가가 필요함을 강조했다. 그들의 연구에서 21개의 공감 대화 시스템을 분석한 결과, 최근 시스템들이 다음 세 가지 측면에서 부족함을 발견했다:

- 구체성 (Specificity): 응답이 일반적이고 진부함
- 반영 수준 (Reflection Levels): 상대방의 감정을 깊이 있게 반영하지 못함
- 다양성 (Diversity): 응답 패턴이 반복적임

본 프로젝트에서는 이 세 가지에 단어 선택과 감정 표현 (Word Choice)을 추가하여 총 4가지 차원으로 평가한다.

메트릭 1: Specificity (구체성)

이론적 기반

구체성 메트릭은 Brysbaert et al. (2014)의 Concreteness Ratings를 기반으로 한다. 이 연구에서는 약 40,000개의 영어 단어에 대해 1점(매우 추상적)부터 5점(매우 구체적)까지의 구체성 점수를 제공한다. 구체적인 응답은 사용자가 자신의 상황이 이해받고 있다고 느끼게 하며, 추상적이고 일반적인 응답보다 더 공감적으로 인식된다 (Truax & Carkhuff, 1964).

Table 1

Concreteness Ratings 예시 (Brysbaert et al., 2014)

단어	구체성 점수	설명
apple	5.00	매우 구체적 - 감각적으로 경험 가능
house	4.93	매우 구체적 - 물리적 대상
friend	4.10	구체적 - 사람을 지칭
situation	3.20	중간 - 맥락에 따라 다름
idea	2.50	추상적 - 개념적
freedom	2.10	매우 추상적 - 비물리적 개념

계산 공식

$$\text{Specificity Score} = (1/N) \times \sum \text{Concreteness}(\text{word}_i)$$

여기서 N 은 Lexicon에서 매칭된 단어 수이고, $\text{Concreteness}(\text{word}_i)$ 는 단어 i 의 구체성 점수(1-5)이다.

구현 코드

```
class SpecificityMetric:
    def compute(self, text: str) -> Dict[str, float]:
        words = self._tokenize(text)
        scores = [self.lexicon[w] for w in words if w in self.lexicon]
        return {
            "score": np.mean(scores),
            "coverage": len(scores) / len(words)
        }
```

메트릭 2: Reflection Level (반영 수준)

이론적 기반

반영 수준 메트릭은 Min et al. (2022)의 PAIR (Prompt-Aware Margin Ranking) 모델과 상담 심리학의 반영 이론을 기반으로 한다. 반영(Reflection)은 상담사가 내담자의 말을 되돌려주는 기술로, 공감적 대화의 핵심 요소이다 (Houck et al., 2012).

Table 2
반영 수준 분류 체계 (Houck et al., 2012; Min et al., 2022)

수준	명칭	설명	예시
0	No Reflection	반영 없음	"What happened next?"
1	Minimal Response	최소 반응	"Okay.", "I see."
2	Simple (Repeat)	단순 반복	"You said you're tired."
3	Simple (Paraphrase)	바꿔 말하기	"So work has been stressful."
4	Feeling (Explicit)	명시적 감정 반영	"You're feeling frustrated."
5	Feeling (Implicit)	암시적 감정 반영	"That sounds overwhelming."
6	Complex Reflection	깊은 의미 해석	"It seems like this means a lot to you."

패턴 기반 탐지

본 구현에서는 규칙 기반(Rule-based) 접근법을 사용하며, 각 수준에 해당하는 언어 패턴을 정규 표현식으로 정의한다.

```
class ReflectionLevelMetric:
    def __init__(self):
        # Level 6: Complex Reflection
        self.complex_patterns = [
            r"it seems like .+ means .+ to you",
            r"beneath .+ there seems to be"
        ]
        # Level 4-5: Feeling Reflection
        self.feeling_patterns = [
            r"you('re| are) feeling",
            r"that must (be|feel|have been)"
        ]
        # Level 2-3: Simple Reflection
        self.simple_patterns = [
            r"so you", r"i understand"
        ]
```

정규화

Normalized Reflection Score = Level / 6

메트릭 3: Word Choice (단어 선택)

이론적 기반

단어 선택 메트릭은 Mohammad (2018)의 NRC VAD (Valence-Arousal-Dominance) Lexicon을 기반으로 한다. 이 프레임워크는 Russell (1980)의 차원적 감정 모델에서 유래하며, 감정을 세 가지 독립적인 차원으로 표현한다.

Table 3

VAD 차원 설명 (Russell, 1980; Mohammad, 2018)

차원	영문	범위	낮은 값	높은 값
정서가	Valence	0-1	부정적, 불쾌	긍정적, 유쾌
각성도	Arousal	0-1	차분, 이완	흥분, 각성
지배성	Dominance	0-1	통제받음, 무력	통제함, 강력

Table 4

감정 단어의 VAD 점수 예시 (NRC VAD Lexicon)

단어	Valence	Arousal	Dominance	해석
happy	0.96	0.74	0.87	긍정, 각성, 통제
calm	0.78	0.22	0.72	긍정, 낮은 각성
sad	0.15	0.32	0.25	부정, 낮은 각성, 무력
angry	0.15	0.85	0.55	부정, 높은 각성
anxious	0.20	0.78	0.25	부정, 높은 각성, 무력

공감 정렬 점수 (Empathy Alignment Score)

공감적 응답의 이상적인 VAD 프로파일을 정의하고, 실제 응답과의 거리를 측정한다:

$$\text{Empathy Alignment} = 1 - (|V - 0.65| + |A - 0.45| + |D - 0.40|) / 3$$

여기서 이상적인 프로파일은: $V_{\text{ideal}} = 0.65$ (약간 긍정적), $A_{\text{ideal}} = 0.45$ (중간 각성), $D_{\text{ideal}} = 0.40$ (낮은 지배성 - 상대방에게 통제권 부여)이다.

메트릭 4: Diversity (다양성)

이론적 기반

다양성 메트릭은 Li et al. (2016)의 Distinct-n 메트릭을 기반으로 한다. 이 메트릭은 신경망 대화 모델이 생성하는 응답의 다양성을 측정하기 위해 개발되었으며, 많은 대화 시스템 연구에서 표준 메트릭으로 사용된다.

Table 5
Distinct-n 메트릭 정의 (Li et al., 2016)

메트릭	수식	설명
Distinct-1	unique unigrams / total unigrams	유니그램 다양성
Distinct-2	unique bigrams / total bigrams	바이그램 다양성
Distinct-3	unique trigrams / total trigrams	트라이그램 다양성

종합 다양성 점수

$$\text{Diversity Score} = 0.4 \times \text{Distinct-1} + 0.6 \times \text{Distinct-2}$$

구현 코드

```
class DiversityMetric:
    def compute(self, text: str) -> Dict:
        tokens = self._tokenize(text)

        # Distinct-1: unique words / total words
        d1 = len(set(tokens)) / len(tokens)

        # Distinct-2: unique bigrams / total bigrams
        bigrams = [tuple(tokens[i:i+2]) for i in range(len(tokens)-1)]
        d2 = len(set(bigrams)) / len(bigrams)

        return {
            "distinct_1": d1,
            "distinct_2": d2,
            "diversity_score": 0.4 * d1 + 0.6 * d2
        }
```

통합 평가기 (Empathy Evaluator)

종합 점수 계산

EmpathyEvaluator 클래스는 4가지 메트릭을 통합하여 종합적인 공감 점수를 계산한다. 각 메트릭은 0-1 범위로 정규화된 후 동일 가중치(25%)로 결합된다.

$$\text{Overall Score} = 0.25 \times \text{Spec} + 0.25 \times \text{Refl} + 0.25 \times \text{Word} + 0.25 \times \text{Div}$$

Table 6

각 차원의 정규화 방법

차원	원본 범위	정규화 공식
Specificity	1-5	$(\text{score} - 1) / 4$
Reflection Level	0-6	$\text{level} / 6$
Word Choice	0-1	그대로 사용
Diversity	0-1	그대로 사용

References

- Brysbaert, M., Warriner, A. B., & Kuperman, V. (2014). Concreteness ratings for 40 thousand generally known English word lemmas. *Behavior Research Methods*, 46(3), 904-911.
- Cuff, B. M., Brown, S. J., Taylor, L., & Howat, D. J. (2016). Empathy: A review of the concept. *Emotion Review*, 8(2), 144-153.
- Davis, M. H. (1983). Measuring individual differences in empathy: Evidence for a multidimensional approach. *Journal of Personality and Social Psychology*, 44(1), 113-126.
- Houck, J. M., Moyers, T. B., Miller, W. R., Glynn, L. H., & Hallgren, K. A. (2012). Motivational Interviewing Skill Code (MISC) 2.5. Unpublished manual.
- Lee, A., Kummerfeld, J. K., An, L., & Mihalcea, R. (2024). A comparative multidimensional analysis of empathetic systems. *Proceedings of EACL*, 179-189.
- Li, J., Galley, M., Brockett, C., Gao, J., & Dolan, B. (2016). A diversity-promoting objective function for neural conversation models. *Proceedings of NAACL-HLT*, 110-119.
- Min, D. J., Pérez-Rosas, V., Resnicow, K., & Mihalcea, R. (2022). PAIR: Prompt-aware margin ranking for counselor reflection scoring. *Proceedings of EMNLP*, 148-158.
- Mohammad, S. M. (2018). Obtaining reliable human ratings of valence, arousal, and dominance for 20,000 English words. *Proceedings of ACL*, 174-184.
- Russell, J. A. (1980). A circumplex model of affect. *Journal of Personality and Social Psychology*, 39(6), 1161-1178.
- Sharma, A., Miner, A., Atkins, D., & Althoff, T. (2020). A computational approach to understanding empathy expressed in text-based mental health support. *Proceedings of EMNLP*, 5263-5276.
- Truax, C. B., & Carkhuff, R. R. (1964). Concreteness: A neglected variable in research in psychotherapy. *Journal of Clinical Psychology*, 20(2), 264-267.